

第二章 线性代数

目录


- [第二章 线性代数](#)
 - [目录](#)
 - [线性代数的表示](#)
 - [矩阵的转置](#)
 - [矩阵相乘投影矩阵](#)
 - [矩阵相乘](#)
 - [投影矩阵](#)
 - [向量的线性相关性与矩阵的秩](#)
 - [单位矩阵与逆矩阵](#)
 - [相似矩阵](#)
 - [空间的基](#)
 - [基与基之间的关系及其求解方法](#)
 - [过渡矩阵的求解方法](#)
 - [相似矩阵](#)
 - [特征值分解与奇异值分解](#)
 - [特征值分解](#)
 - [奇异值分解与伪逆](#)
 - [向量的范数](#)

线性代数的表示

- 标量(Scalars)
单个数值：整数5、实数0.5、有理数1/3等
用小写字母表示，如 a, n, x
- 向量(Vectors)
一维数组，无特别说明，即指列向量
加粗小写，如

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} = (x_1, x_2, \dots, x_n)^T$$

- 矩阵(Matrix)
二维数组
大写字母表示 $A_{m \times n}$ 或 $A \in R^{m \times n}$
向量可视为 $m \times 1$ 的矩阵
- 张量(Tensor)
数组的扩展



矩阵的转置

- 定义：行、列坐标互换，行变列，列变行

$$(A^T)_{i,j} = A_{j,i}$$

如：

$$A_{3 \times 2} = \begin{bmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \\ A_{3,1} & A_{3,2} \end{bmatrix} \text{ 则 } A_{2 \times 3}^T = \begin{bmatrix} A_{1,1} & A_{2,1} & A_{3,1} \\ A_{1,2} & A_{2,2} & A_{3,2} \end{bmatrix}$$

矩阵的转置有性质：

$$(AB)^T = B^T A^T$$

矩阵相乘投影矩阵

矩阵相乘

- 计算方法1：元素为列乘以行

有矩阵 $A_{m \times n}$ $B_{l \times k}$ 若 $n = l$ ， AB 存在

矩阵 A B 相乘，其元素由下式计算

$$(AB)_{i,j} = \sum_k A_{i,k} B_{k,j}$$

如

$$AB = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} (1,2,3)(1,2,3)^T & (1,2,3)(4,5,6)^T \\ (4,5,6)(1,2,3)^T & (4,5,6)(4,5,6)^T \end{bmatrix}$$

- 计算方法2：行乘以列的各矩阵相加

$$AB = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} = (1,4)(1,4)^T + (2,5)(2,5)^T + (3,6)(3,6)^T = \begin{bmatrix} 1 & 4 \\ 4 & 16 \end{bmatrix} + \begin{bmatrix} 4 & 10 \\ 10 & 25 \end{bmatrix} + \begin{bmatrix} 9 & 18 \\ 18 & 36 \end{bmatrix}$$

- 怎么应用

行的线性组合可通过左乘行向量取得

$$\begin{bmatrix} c_1 & c_2 \end{bmatrix} \begin{bmatrix} a_1 & a_2 \\ a_3 & a_4 \end{bmatrix} = \begin{bmatrix} c_1 a_1 + c_2 a_3 & c_1 a_2 + c_2 a_4 \end{bmatrix}$$

同理，列的线性组合可通过右乘列向量

$$\begin{bmatrix} a_1 & a_2 \\ a_3 & a_4 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} c_1 a_1 & c_2 a_2 \\ c_1 a_3 & c_2 a_4 \end{bmatrix}$$

- 如何理解

考虑以 r 为半径，自 x 轴正方向逆时针旋转角度 α 所得的向量 $(x, y)^T$ ，其坐可表示为

$$\begin{cases} x = r \cos(\alpha) \\ y = r \sin(\alpha) \end{cases}$$

对其进行旋转变换，逆时针旋转角度 θ ，旋转后坐标为 $(x', y')^T$

则有

$$\begin{cases} x' = r \cos(\alpha + \theta) \\ y' = r \sin(\alpha + \theta) \end{cases}$$

应用三角公式可得

$$\begin{cases} x' = x \cos \theta - y \sin \theta \\ y' = x \sin \theta + y \cos \theta \end{cases}$$

系数可表示为矩阵

$$A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

考虑将 x 经过两次旋转，角度分别为 ψ 和 θ ，则系数可表示为

$$C = \begin{bmatrix} \cos(\psi + \theta) & -\sin(\psi + \theta) \\ \sin(\psi + \theta) & \cos(\psi + \theta) \end{bmatrix} = \begin{bmatrix} \cos \theta \cos \psi - \sin \theta \sin \psi & -\sin \theta \cos \psi - \cos \theta \sin \psi \\ \sin \theta \cos \psi + \cos \theta \sin \psi & \cos \theta \cos \psi - \sin \theta \sin \psi \end{bmatrix}$$


再观察

$$A = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} B = \begin{bmatrix} \cos \psi & -\sin \psi \\ \sin \psi & \cos \psi \end{bmatrix}$$

C 各元素可由 A 的对应行乘 B 的对应列所得，于是由此规定矩阵乘法

投影矩阵

若 $Ax = b$ 无解，则可转而求 $A^T A \hat{x} = A^T b$



$$a \perp e$$

$$\text{从而 } a^T(b - p) = 0$$

$$\text{即 } a^T(b - xa) = 0$$

$$\text{故 } x = \frac{a^T b}{a^T a} \quad p = \frac{aa^T}{a^T a} b = Pb$$

$$P = \frac{aa^T}{a^T a} \quad \text{被称为投影矩阵}$$

$n \times n$

$$\text{易证 } A = \begin{bmatrix} a_1 & a_2 \end{bmatrix} \text{ 时 } P = A(A^T A)^{-1} A^T$$

若 A 可逆，则 $P = I$ ，即无需投影

对任意投影矩阵，有性质 $P^T = P$ 及 $P^2 = P$ ，即朝一个方向反复投影，结果不变

向量的线性相关性与矩阵的秩

- 定义

对向量组 $x_1, x_2, \dots, x_s (s \geq 1)$ 若存在一组不全为0的数

$$k_1, \dots, k_s$$

使得

$$k_1 x_1 + \dots + k_s x_s = 0$$

则称该向量组线性相关，反之，则线性无关

线性无关的充要条件：其中任何一个向量不能由其余向量线性表出

- 极大线性无关组

对于一个向量组 x_1, \dots, x_s ，若存在一个部分组，满足：

这个部分组线性无关

如果从向量组的其余部分中任取一个添加进去，则到的新部分组都线性相关，则这个部分组称为向量组 $\mathbf{x}_1, \dots, \mathbf{x}_s$ 的极大线性无关组

向量组与它的任意一个极大线性无关组等价（等价——互可线性表出）
不含零向量的向量组如果线性相关，则它的极大线性无关组肯定不止一个

- 正交向量组
若向量 α 和 β 的内积为零，即 $\alpha^T \beta = 0$ ，则称 α 与 β 正交，记为 $\alpha \perp \beta$
若不含零的向量组 α_i 内的向量两两相交，则 α_i 为正交向量组
若一个正交向量组内的任一个向量是单位向量，则说向量组是**标准正交向量组**
- 向量组的秩
向量组的一个极大线性无关组所含的向量的个数，记为 $\text{rank}\{\mathbf{x}_1, \dots, \mathbf{x}_s\}$
- 矩阵的秩
矩阵的列向量组的秩称为 A 的列秩， A 的行向量组的秩称为 A 的行秩
任一矩阵的行秩等于其列秩，统称为矩阵 A 的秩，记作 $\text{rank}(A)$

单位矩阵与逆矩阵

- 方阵：行数等于列数 $A_{n \times n}$
- 对角矩阵：对于一个方阵，对角线外的元素均为零，即为对角矩阵
- 单位矩阵：对于一个对角矩阵，对角线上的元素均为1，即为单位矩阵，用 I_n 表示
- 逆矩阵：对方阵 A_n ，若存在方阵 B_n 使得 $AB = BA = I$ ，则 A 为可逆矩阵， B 与 A 互为逆矩阵
- 矩阵可逆的等价条件
- A 为满秩矩阵(满秩矩阵——矩阵的秩等于方阵的列数/行数)
- A 的各列线性无关
- 非满秩方阵称为**奇异矩阵**

相似矩阵

空间的基

线性空间 V 中的 n 个线性无关向量 $\alpha_1, \dots, \alpha_n$ ，且 V 中任何一个向量都可由其线性表出，

$$\alpha = k_1 \alpha_1 + \dots + k_n \alpha_n$$

则称其为 V 的一个基， $(k_1, \dots, k_n)^T$ 为 α 在该基下的坐标

由 n 个标准正交向量组成的基称为标准正交基，标准正交基不唯一

求矩阵标准正交基的方法——Gram-Schmidt正交化：

- 对第一个基直接取用 $\beta_1 = \alpha_1$
- 第2个基减去在第一个基上的投影 $\beta_2 = \alpha_2 - \frac{\alpha_2^T \beta_1}{\beta_1^T \beta_1} \beta_1$
- 第 n 个基减去在第1到第 $n-1$ 个基上的投影，以此类推

以上方法得到的正交基，可以有多个，并不唯一

基与基之间的关系及其求解方法

设 $\alpha_1, \dots, \alpha_n$ 与 β_1, \dots, β_n 为 V 中的两组基，它们的关系可表示为

$$\beta_i = (\alpha_1, \dots, \alpha_n) \begin{bmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{bmatrix}$$

用矩阵可表示为

$$(\beta_1, \dots, \beta_n) = (\alpha_1, \dots, \alpha_n) \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix}$$

右侧称为过渡矩阵，每一列对应右侧一个基向量过渡到左侧一个基向量的系数

过渡矩阵的求解方法

- 直观求解，直接取得二者向量的对应关系，如 $\beta_i = A\alpha_i$ ，直接将 α_i 写作过渡矩阵的各列即可
- 若 A, B 均为方阵，则可对 $[A|B]$ 辅助矩阵进行初等变换，令左侧为单位矩阵，则右侧即为过渡矩阵，方法同求矩阵的逆
证明： $B = AP \Rightarrow P = A^{-1}B$ 对辅助矩阵 $[A|B] \Rightarrow [A^{-1}A|A^{-1}B] \Rightarrow [I|P]$
注记：可见，凡是涉及单个矩阵求逆的运算，均可用辅助矩阵求解
待证明，当 AB 不为方阵时，该方法同样有效，逆矩阵替换为左伪逆

相似矩阵

有矩阵在两组基 $\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n$ 的表示下分别为 A 与 B ，两组基的过渡矩阵为 P ，则有

$$B = P^{-1}AP$$

将以上式推广，则得出相似矩阵的定义：若存在 $B = P^{-1}AP$ ，则称 A 与 B 相似

相似矩阵，事实上是将同一坐标系相形状相同的矩阵归为一类，尽管从同一个角度看，二者并不相同，但本质上，二者的形状完全一样，那么，是否存在一个坐标系，使得相同形状的矩阵获得相同的表示呢？这就是特征值和特征矩阵，尽管每个矩阵各有其特征向量，这代表了他们映射到目标坐标的不同姿势，但特征值暴露了他们形状相同的本质

特征值分解与奇异值分解

特征值分解

- 对矩阵 A ，有与之平行的向量 v ，二者关系表示为

$$Av = \lambda v$$

要求得上式的 v 与 λ ，或求解方程 $|\lambda E - A| = 0$

如：对矩阵

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

解方程 $\lambda E - A = (\lambda - 2)^2(\lambda - 6)$

取得特征值 $\lambda_1 = \lambda_2 = 2, \lambda_3 = 6$

将 λ_i 代入方程 $(\lambda I - A) = 0$ 可求得与对角矩阵

$$\Lambda = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 3 \end{bmatrix}$$

对应的特征矩阵


$$V = \begin{bmatrix} -1 & 1 & 1 \\ 1 & 0 & -2 \\ 0 & 1 & 3 \end{bmatrix}$$

当 n 阶矩阵 A 有 n 个线性无关特征向量 (P 可逆) 时, 矩阵可对角化为

$$P^{-1}AP = \text{diag}(\lambda_1, \dots, \lambda_n)$$

即

$$A = P\Lambda P^{-1}$$



正定矩阵的特征向量相互正交, 实对称矩阵为正定矩阵, 对正定矩阵有

$$A = Q\Lambda Q^T$$

例如, 有一二次曲线, 方程为

$$5x^2 + 4xy + 2y^2 - 2 = 0$$

很难从方程上直观得到曲线的形状, 将方程列改写为矩阵相乘的形式, 且使得系数矩阵为实对称矩阵

$$(x, y) \begin{bmatrix} 5 & 2 \\ 2 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$

对系数矩阵进行特征值分解, 可得到其特征值和正交特征向量组, 将特征向量组单位化, 有


$$\Lambda = \begin{pmatrix} 1 \\ 6 \end{pmatrix}^T = \begin{bmatrix} 1/\sqrt{5} & 2/\sqrt{5} \\ -2/\sqrt{5} & 1/\sqrt{5} \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

令新坐标为 (x', y') ，则有

$$(x', y')^T A^T A (x', y')^T = (x', y') \begin{bmatrix} 1 & 0 \\ 0 & 6 \end{bmatrix} \begin{bmatrix} x' \\ y' \end{bmatrix} = x'^2 + 6y'^2$$

故原方程变为 $x'^2 + y'^2 - 2 = 0$ ，即 $x'^2 + y'^2 = 2$

很明显是一个椭圆



奇异值分解与伪逆

问：特征值分解仅对方阵有效，非方阵如何取得近似？

答：构造实对称矩阵—— $A^T A$ 与 AA^T (二者均为对称矩阵)，对二者进行特征值分解，再开根号

设 $A = U\Sigma V^{-1} = U\Sigma V^T$ 则

$$A^T A = V\Sigma U^T U\Sigma V^T = V\Sigma^2 V^T$$

$$AA^T = U\Sigma V^T V\Sigma U^T = U\Sigma^2 U^T$$

V 为 $A^T A$ 的特征向量单位化矩阵

U 为 AA^T 的特征向量单位化矩阵

Σ 为 $A^T A$ 的特征值开方对角矩阵

与之思路类似，非方阵与不可逆矩阵可求左右伪逆
 A 不可逆，但 $A^T A$ 可逆，对列满秩矩阵，有

$$(A^T A)^{-1} (A^T A) = I$$

即

$$[(A^T A)^{-1} A^T] A = I$$

括号中即为左伪逆，同理可得行满秩矩阵的右伪逆

$$A [A^T (A A^T)^{-1}] = I$$

向量的范数

- 向量的大小用**范数**来衡量，形式上，

$$L^p$$

范数定义

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

$$\left\| \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\|_2 = \sqrt{1^2 + 2^2 + 3^2}$$

范数满足下列性质

- 非负性：若 $\mathbf{x} \neq \mathbf{0}$ ，则 $f(\mathbf{x}) > 0$ ； $f(\mathbf{x}) = 0 \Rightarrow \mathbf{x} = \mathbf{0}$
- 三角不等式（不要与凸函数性质混淆）： $f(\mathbf{x} + \mathbf{y}) \leq f(\mathbf{x}) + f(\mathbf{y})$
- 齐次性： $\forall \alpha \in \mathbb{R}, f(\alpha \mathbf{x}) = |\alpha| f(\mathbf{x})$
- 几个常见范数
- L2范数

$$p = 2$$

，欧里几得范数 $L^2 = x^T x$ ，机器学习中最常用

推广至矩阵Frobenius norm $\|A\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}$

- L1范数 $p = 1$ ， $L^1 = \|\mathbf{x}\|_1 = \sum_i |x_i|$ ，也较常用
- 最大范数 $\|\mathbf{x}\|_\infty = \max_i |x_i|$

正则化效果(结合带有不等式约束的极值求解)

